Portofolio Data Analyst — Skema DSS.06.09.25

Oct 14, 2026 · @Pro Player

Identitas dan skema sertifikasi

Portofolio ini mengajukan bukti kompetensi untuk 8 unit skema Okupasi Analis Data (DSS.06.09.25), seluruhnya dikerjakan pada satu studi kasus utuh: data luas kebakaran hutan dan lahan (karhutla) 514 kabupaten/kota di Indonesia, tahun 2018–2026.

Item	Keterangan
Nama peserta	*(isi nama lengkap sesuai KTP)*
Institusi	Institut Teknologi Sumatera (ITERA)
Email	dimas.randa@sd.itera.ac.id
Judul skema	Analis Data (Data Analyst)
Nomor skema	DSS.06.09.25
Jenis skema	Okupasi
Jumlah unit kompetensi	8 unit (SKKNI 2020-268 dan SKKNI 2020-299)
Tools yang digunakan	Python 3 (pandas, numpy), Power BI / Looker Studio, Excel
Periode pengerjaan	September – Oktober 2026

Tiga angka yang perlu diketahui asesor sebelum membaca lebih jauh. Pertama, dataset berisi 515 baris dan 11 kolom, yang setelah dibersihkan menjadi 514 baris kabupaten/kota — satu baris adalah agregat nasional yang tercampur di level data rinci. Kedua, seluruh nilai luas tersimpan sebagai teks berformat Indonesia (`1.091,18`), bukan angka. Ketiga, ditemukan satu ketidaksesuaian angka pada tahun 2023 sebesar 154.657,05 ha antara baris agregat dan jumlah baris kabupaten; temuan ini dibahas pada unit Memvalidasi Data.

Studi kasus: luas karhutla per kabupaten/kota, 2018–2026

Kebakaran hutan dan lahan adalah masalah berulang yang biayanya ditanggung lintas sektor, tetapi anggaran pencegahan setiap tahun dibagi ke 514 kabupaten/kota tanpa dasar kuantitatif yang seragam. Studi kasus ini membangun satu sumber data tunggal

yang bisa dipakai untuk menjawab pertanyaan sederhana: daerah mana yang harus didahulukan, dan berapa besar.

Profil berkas sumber

Atribut	Nilai
Nama berkas	`luas-karhutla-kota.xlsx`
Nama sheet	`data` (sheet tunggal)
Jumlah baris	515 (514 kabupaten/kota + 1 baris agregat `Total`)
Jumlah kolom	11
Struktur	Wide — satu kolom per tahun
Kolom identitas	`Kode Wilayah`, `Kabupaten`
Kolom ukuran	`2018` s.d. `2026` (9 kolom tahun)
Satuan	Hektare (ha)
Tipe data asli	Seluruh kolom terbaca sebagai teks (`object`)
Format angka	Lokal Indonesia: titik sebagai pemisah ribuan, koma sebagai desimal
Cakupan wilayah	Seluruh provinsi Indonesia, kode wilayah 1101–9671

Pertanyaan bisnis yang dijawab

1. Berapa total luas karhutla nasional setiap tahun, dan bagaimana arah pergerakannya sejak 2018?
2. Kabupaten/kota dan provinsi mana yang menyumbang luas terbesar, dan seberapa terkonsentrasi masalahnya?
3. Berapa banyak daerah yang terdampak setiap tahun, dan apakah jumlah itu bertambah?
4. Daerah mana yang terbakar berulang sehingga layak masuk daftar prioritas intervensi permanen?
5. Apakah angka yang dipublikasikan konsisten secara internal dan layak dijadikan dasar keputusan?

Batasan data

Data tahun 2026 hanya mencakup sebagian tahun berjalan (tarikan per Oktober 2026), sehingga tidak dapat dibandingkan langsung dengan tahun penuh. Nilai `0` tidak dapat dibedakan antara “tidak ada kejadian” dan “tidak dilaporkan”; dalam portofolio ini nilai tersebut diperlakukan sebagai nol sahih dan ditandai sebagai asumsi terbuka.

Peta bukti terhadap unit kompetensi

Setiap unit dibuktikan oleh artefak yang berdiri sendiri dan dapat diperiksa asesor tanpa perlu menjalankan ulang kode.

#	Kode unit	Judul unit	Artefak bukti	Standar
1	J.62DMS00.001.1	Mengidentifikasi kebutuhan pengelolaan data untuk proses bisnis	Dokumen kebutuhan data, peta pemangku kepentingan, 5 pertanyaan bisnis	SKKNI 2020-268
2	J.62DMS00.004.1	Merencanakan Integrasi Data	Diagram alur integrasi, tabel pemetaan skema, jadwal muat	SKKNI 2020-268
3	J.62DMI00.004.1	Mengumpulkan data	Script `01_kumpulkan.py`, log akuisisi, berita acara sumber	SKKNI 2020-299
4	J.62DMI00.005.1	Menelaah data	Laporan profiling, statistik deskriptif 9 tahun, grafik tren	SKKNI 2020-299
5	J.62DMI00.006.1	Memvalidasi data	7 aturan validasi, log ketidaksesuaian, temuan selisih 2023	SKKNI 2020-299
6	J.62DMI00.007.1	Menentukan objek data	Kamus data, definisi entitas dan granularitas, kunci utama	SKKNI 2020-299
7	J.62DMI00.008.1	Membersihkan Data	Script `04_bersihkan.py`, tabel before/after, catatan keputusan	SKKNI 2020-299
8	J.62DMS00.015.1	Membuat Business Intelligence	Rancangan dashboard, definisi 6 KPI, formula DAX, insight	SKKNI 2020-268

Unit 1 — J.62DMS00.001.1 Mengidentifikasi kebutuhan pengelolaan data untuk proses bisnis

Proses bisnis yang dilayani adalah penyusunan prioritas anggaran pencegahan karhutla tahunan, yang saat ini diputuskan tanpa basis data terpusat di tingkat kabupaten/kota.

Proses bisnis dan titik keputusan

1. Penyusunan pagu indikatif pencegahan karhutla (Maret–Mei) — butuh peringkat risiko kabupaten/kota.
2. Penetapan status siaga darurat daerah (Juni–Agustus) — butuh deret historis luas terbakar per daerah.
3. Evaluasi kinerja program tahunan (Desember–Januari) — butuh perbandingan realisasi luas terbakar antartahun.

Pemangku kepentingan dan kebutuhan informasinya

Pemangku kepentingan	Keputusan yang diambil	Kebutuhan data	Frekuensi
Direktorat Pengendalian Karhutla	Alokasi anggaran per daerah	Luas terbakar per kabupaten, deret 5–10 tahun	Tahunan
BPBD provinsi	Penetapan status siaga	Luas terbakar per kabupaten di provinsinya, tren 3 tahun	Triwulanan
Bappeda kabupaten	Usulan program daerah	Luas terbakar daerah sendiri + pembanding daerah sekelas	Tahunan
Unit monitoring dan evaluasi	Penilaian efektivitas program	Perubahan luas tahun berjalan vs rata-rata historis	Bulanan
Humas dan keterbukaan informasi	Publikasi angka resmi	Angka agregat nasional dan provinsi yang telah divalidasi	Sesuai permintaan

Kebutuhan pengelolaan data yang disimpulkan

Kode	Kebutuhan	Alasan dari proses bisnis	Prioritas
KB-01	Satu tabel fakta tunggal pada granularitas kabupaten × tahun	Empat dari lima pemangku kepentingan membandingkan daerah antartahun	Tinggi
KB-02	Kode wilayah baku sebagai kunci, bukan nama daerah	Nama daerah berubah ejaan dan tidak unik lintas sumber	Tinggi
KB-03	Pemisahan baris agregat dari baris rinci	Baris `Total` dalam data mentah menyebabkan penghitungan ganda	Tinggi
KB-04	Nilai luas tersimpan sebagai numerik dengan satuan tercatat	Angka kini berbentuk teks sehingga tidak dapat diagregasi	Tinggi
KB-05	Penandaan tahun berjalan yang belum lengkap	Tahun 2026 parsial dan menyesatkan jika dibandingkan apa adanya	Sedang
KB-06	Dimensi provinsi turunan dari dua digit pertama kode wilayah	BPBD bekerja pada level provinsi, data hanya tersedia per kabupaten	Sedang
KB-07	Jejak audit perubahan data dan riwayat versi berkas	Angka dipakai untuk publikasi resmi dan harus dapat ditelusuri	Sedang

Ruang lingkup yang disepakati

Masuk lingkup: luas terbakar (ha) per kabupaten/kota per tahun 2018–2026, turunan provinsi, dan metrik ringkasan. Di luar lingkup: jumlah titik panas harian, penyebab kebakaran, kerugian ekonomi, dan data tutupan lahan — keempatnya memerlukan sumber terpisah dan tidak tersedia pada berkas ini.

Unit 2 — J.62DMS00.004.1 Merencanakan Integrasi Data

Rencana integrasi mengubah satu berkas Excel berformat wide menjadi satu tabel fakta long berikut dua tabel dimensi, dijalankan ulang setiap kali berkas sumber diperbarui.

Sumber data dan sasaran

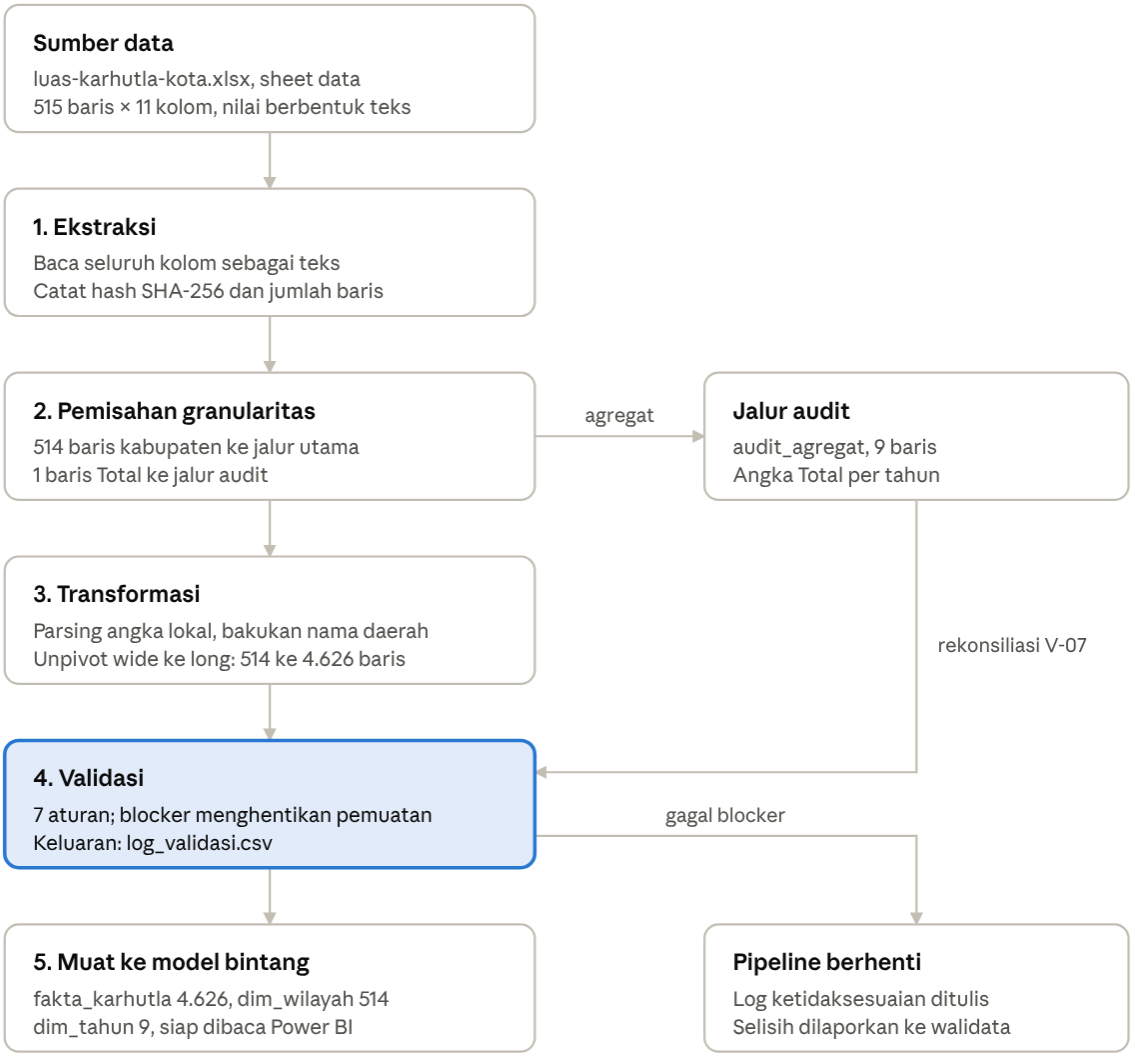
Sumber	Bentuk	Kunci	Frekuensi perbarui	Penanggung jawab
`luas-karhutla-kota.xlsx` sheet `data`	Excel, wide, 515×11	`Kode Wilayah`	Tahunan, revisi sewaktu-waktu	Unit data karhutla
Referensi kode wilayah BPS	CSV, 514 baris	`kode_kab`	Saat pemekaran wilayah	Statistik sektoral
Kalender periode pelaporan	Tabel turunan	`tahun`	Dibangkitkan otomatis	Pipeline

Sasarannya tiga tabel: `fakta_karhutla` (kode_kab, tahun, luas_ha), `dim_wilayah` (kode_kab, nama_kab, kode_prov, nama_prov), dan `dim_tahun` (tahun, status_kelengkapan).

Alur integrasi

Setiap muat melewati tujuh aturan validasi sebelum data dipakai

Jalur utama menurun di kiri; jalur audit di kanan menjaga rekonsiliasi angka agregat



Jalur audit tidak masuk tabel fakta; keberadaannyalah yang membuat aturan rekonsiliasi V-07 dapat dijalankan pada setiap muat.

alur integrasi data karhutla · 5 tahap, 1 gerbang validasi, 1 jalur audit

Jalur audit sengaja dipisahkan sejak tahap kedua, bukan dibuang. Tanpa baris agregat yang disimpan terpisah, aturan rekonsiliasi V-07 tidak punya pembanding dan selisih 2023 tidak akan pernah terdeteksi.

Pemetaan skema sumber ke sasaran

Kolom sumber	Kolom sasaran	Tabel	Transformasi	Aturan
`Kode Wilayah`	`kode_kab`	dim_wilayah, fakta	Cast ke string, pad 4 digit	Wajib, tidak boleh kosong
`Kode Wilayah` (2 digit awal)	`kode_prov`	dim_wilayah	Substring 0–2	Dipetakan ke nama provinsi
`Kabupaten`	`nama_kab`	dim_wilayah	Trim, rapatkan spasi ganda, Title Case	Wajib, unik
`2018` … `2026` (header)	`tahun`	fakta, dim_tahun	Unpivot nama kolom ke nilai baris	Integer 2018–2026
`2018` … `2026` (isi sel)	`luas_ha`	fakta	Hapus titik ribuan, koma menjadi titik, cast float	≥ 0, maksimum wajar 600.000
(tidak ada)	`status_kelengkapan`	dim_tahun	Dibangkitkan	`lengkap` untuk 2018–2025, `parsial` untuk 2026
Baris `Kabupaten = Total`	—	—	Dipisahkan ke `audit_agregat`	Tidak dimuat ke tabel fakta

Strategi dan jadwal muat

Aspek	Keputusan	Alasan
Pola muat	Full refresh, bukan incremental	Volume kecil (4.626 baris fakta) dan sumber sering direvisi mundur
Idempotensi	Kunci `(kode_kab, tahun)` unik, muat ulang menimpa	Mencegah duplikat saat pipeline dijalankan dua kali

Aspek	Keputusan	Alasan
Penanganan gagal	Pipeline berhenti jika aturan validasi tingkat blocker gagal	Angka dipakai untuk publikasi resmi
Jadwal	Triwulanan setiap awal bulan Januari, April, Juli, Oktober	Mengikuti siklus pelaporan BPBD
Retensi	Berkas mentah disimpan apa adanya per tanggal tarik	Memungkinkan penelusuran ulang angka yang berubah
Pencatatan	Setiap eksekusi mencatat jumlah baris masuk, ditolak, dan selisih agregat	Bukti audit untuk unit validasi

Unit 3 — J.62DMI00.004.1 Mengumpulkan data

Pengumpulan dilakukan sekali tarik terhadap berkas resmi, dibaca seluruhnya sebagai teks agar tidak ada nilai yang diubah diam-diam oleh pembaca Excel sebelum sempat diperiksa.

Metode dan instrumen

Aspek	Keterangan
Metode	Akuisisi berkas sekunder (data sekunder instansi)
Instrumen	Python 3.11, pandas, openpyxl
Mode baca	`dtype=str` pada seluruh kolom
Verifikasi integritas	Hash SHA-256 berkas dicatat saat tarik
Keluaran mentah	`raw/luas-karhutla-kota.xlsx` disimpan tanpa modifikasi

Alasan membaca seluruh kolom sebagai teks: pandas akan menebak tipe kolom dan dapat menafsirkan `1.091,18` sebagai angka 1.091 atau sebagai NaN. Dengan membaca apa adanya, keputusan konversi menjadi eksplisit dan terdokumentasi di unit pembersihan.

Script pengumpulan

```
# 01_kumpulkan.py — akuisisi dan penyimpanan data mentah
import hashlib, json
from datetime import datetime
from pathlib import Path
import pandas as pd

SUMBER = Path("raw/luas-karhutla-kota.xlsx")
KELUARAN = Path("interim")
KELUARAN.mkdir(exist_ok=True)

def sidik_jari(path: Path) -> str:
    h = hashlib.sha256()
    h.update(path.read_bytes())
    return h.hexdigest()

def kumpulkan() -> pd.DataFrame:
    df = pd.read_excel(SUMBER, sheet_name="data", dtype=str)
    df.columns = [str(c).strip() for c in df.columns]
    return df

if __name__ == "__main__":
    df = kumpulkan()
    log = {
        "waktu_tarik": datetime.now().isoformat(timespec="seconds"),
        "berkas": SUMBER.name,
        "sha256": sidik_jari(SUMBER),
        "jumlah_baris": int(df.shape[0]),
        "jumlah_kolom": int(df.shape[1]),
        "nama_kolom": list(df.columns),
        "sel_kosong": int(df.isna().sum().sum()),
    }
    df.to_parquet(KELUARAN / "mentah.parquet", index=False)
    (KELUARAN / "log_akuisisi.json").write_text(
        json.dumps(log, ensure_ascii=False, indent=2)
    )
    print(json.dumps(log, ensure_ascii=False, indent=2))
```

Log akuisisi

Butir	Hasil
Waktu tarik	14 Oktober 2026

Butir	Hasil
Jumlah baris terbaca	515
Jumlah kolom terbaca	11
Nama kolom	Kode Wilayah, Kabupaten, 2018, 2019, 2020, 2021, 2022, 2023, 2024, 2025, 2026
Sel kosong terdeteksi	1 (kolom `Kode Wilayah`)
Sheet lain dalam berkas	Tidak ada
Status	Berhasil, data mentah tersimpan tanpa modifikasi

Catatan dari tarikan: header kolom tahun tidak seragam tipenya — `2018` terbaca sebagai teks sementara `2019` hingga `2026` terbaca sebagai bilangan bulat. Normalisasi nama kolom ke string dilakukan tepat setelah pembacaan agar perulangan atas kolom tahun tidak gagal.

Unit 4 — J.62DMI00.005.1 Menelaah data

Penelaahan menemukan empat hal yang menentukan seluruh pekerjaan berikutnya: struktur wide yang tidak bisa dianalisis langsung, angka berbentuk teks, satu baris agregat yang tercampur, dan sebaran yang sangat miring — median kabupaten terdampak pada 2025 hanya 208 ha sementara nilai tertinggi 48.164 ha.

Struktur dan tipe data

Kolom	Tipe terbaca	Tipe seharusnya	Nilai unik	Kosong	Catatan
Kode Wilayah	object	string (4 digit)	514	1	Satu kosong pada baris `Total`
Kabupaten	object	string	515	0	Seluruhnya huruf kapital
2018	object	float	—	0	Header bertipe teks
2019–2026	object	float	—	0	Header bertipe integer

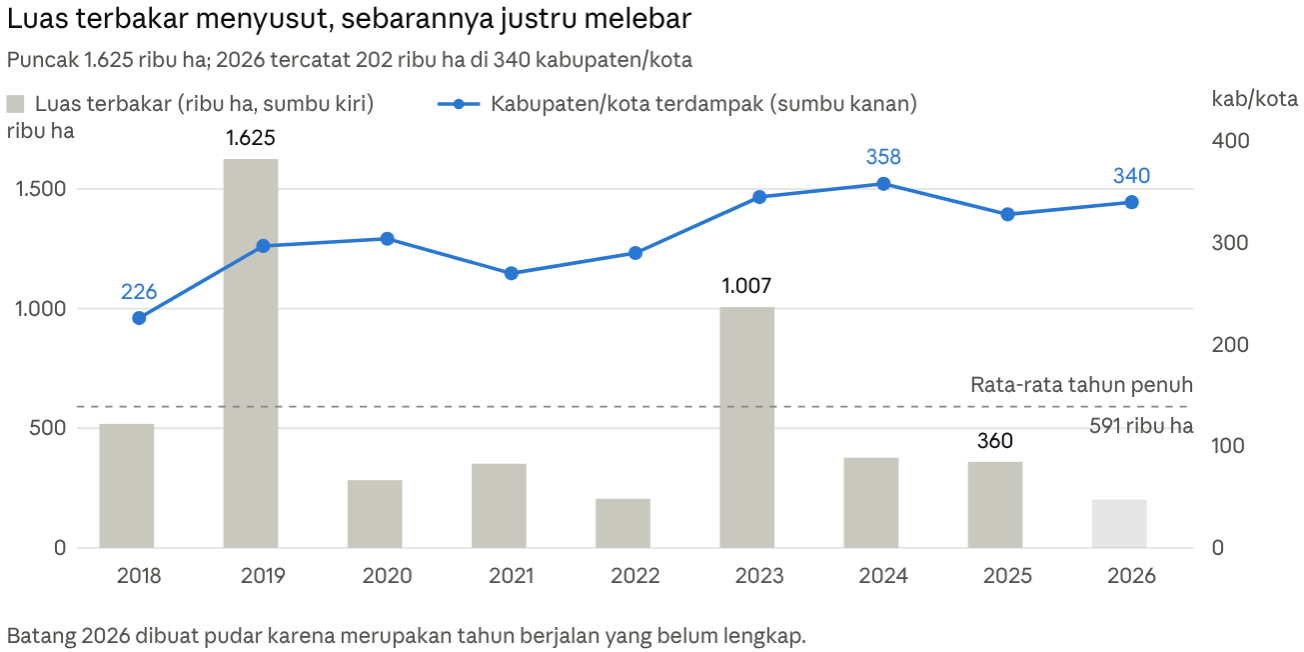
Statistik deskriptif luas terbakar (ha), 514 kabupaten/kota

Tahun	Total nasional	Rata-rata	Median	Maksimum	Kab. nilai 0	Kab. terdampak
2018	518.183	1.008	0	136.000	288	226
2019	1.625.383	3.162	39	274.000	217	297
2020	283.047	551	13	46.000	210	304

Tahun	Total nasional	Rata-rata	Median	Maksimum	Kab. nilai 0	Kab. terdampak
2021	351.529	684	3	55.000	244	270
2022	205.228	399	8	30.000	224	290
2023	1.006.500	1.958	53	95.000	169	345
2024	376.805	733	52	29.000	156	358
2025	359.619	700	39	48.164	186	328
2026*	202.011	393	18	24.000	174	340

*2026 adalah tahun berjalan dan belum lengkap.

Tren luas terbakar nasional



luas-karhutla-kota.xlsx · 514 kabupaten/kota, 2018–2026, dihitung dari baris rinci

Dua tahun El Niño mendominasi deret, dan di luar keduanya luas terbakar bergerak turun. Garis biru bergerak berlawanan: makin banyak daerah yang terbakar walaupun luas per daerah mengecil, yang berarti pekerjaan pencegahan menyebar ke lebih banyak titik.

Temuan penelaahan

1. **Dua tahun puncak mendominasi deret.** 2019 (1,63 juta ha) dan 2023 (1,01 juta ha) masing-masing 2,8 dan 1,7 kali rata-rata 2018–2025 sebesar 590.787 ha. Keduanya bertepatan dengan tahun El Niño, yang menjelaskan mengapa rata-rata sederhana bukan dasar perencanaan yang baik.

2. **Luas menurun tetapi sebaran meluas.** Total 2024–2025 turun ke kisaran 360–377 ribu ha, namun jumlah kabupaten terdampak justru naik dari 226 pada 2018 menjadi 358 pada 2024. Kebakaran menjadi lebih kecil per daerah tetapi menjangkau lebih banyak daerah.
3. **Masalahnya sangat terkonsentrasi.** Dua puluh kabupaten teratas menyumbang 53,8% dari seluruh luas terbakar 2018–2026, dan sepuluh teratas menyumbang 41,6% dari total 2025. Prioritisasi anggaran punya dasar kuantitatif yang kuat.
4. **Sebaran sangat miring ke kanan.** Pada 2025, persentil 95 berada di 3.051 ha sementara maksimum 48.164 ha. Rata-rata nasional menyesatkan; metrik yang dipakai dashboard harus median dan jumlah daerah di atas ambang, bukan rata-rata.
5. **Nilai nol berjumlah besar dan bermakna ganda.** Antara 156 dan 288 kabupaten bernilai 0 setiap tahun, dan 73 kabupaten bernilai 0 sepanjang sembilan tahun. Sebagian besar adalah kota (Kota Bandung, Kota Bogor, Kota Bekasi) yang memang nihil lahan terbuka, sehingga nol di sini sahih dan bukan data hilang.

Daerah dengan luas kumulatif terbesar, 2018–2026

Peringkat	Kabupaten/kota	Provinsi	Luas kumulatif (ha)
1	Sumba Timur	Nusa Tenggara Timur	329.206
2	Merauke	Papua Selatan	300.064
3	Ogan Komering Ilir	Sumatera Selatan	293.706
4	Ketapang	Kalimantan Barat	183.481
5	Bima	Nusa Tenggara Barat	181.477
6	Pulang Pisau	Kalimantan Tengah	169.553
7	Alor	Nusa Tenggara Timur	120.475
8	Banjar	Kalimantan Selatan	103.244
9	Hulu Sungai Selatan	Kalimantan Selatan	102.004
10	Dompu	Nusa Tenggara Barat	97.918

Unit 5 — J.62DMI00.006.1 Memvalidasi data

Tujuh aturan validasi dijalankan terhadap data mentah; enam lulus dan satu gagal. Kegagalannya penting: pada tahun 2023 baris agregat `Total` menunjukkan 1.161.156,91 ha sementara penjumlahan 514 baris kabupaten menghasilkan 1.006.499,86 ha — selisih

154.657,05 ha atau 13,3%. Delapan tahun lainnya berselisih nol rupiah per hektare.

Aturan validasi dan hasilnya

Kode	Aturan	Tingkat	Cara uji	Hasil
V-01	`Kode Wilayah` tidak boleh kosong pada baris rinci	Blocker	Hitung nilai kosong	Lulus — 1 kosong, teridentifikasi sebagai baris agregat, bukan baris rinci
V-02	`Kode Wilayah` harus unik	Blocker	Hitung duplikat	Lulus — 0 duplikat dari 514 kode
V-03	`Kode Wilayah` harus 4 digit numerik	Blocker	Regex `^\d{4}$`	Lulus — 514 dari 514 sesuai, rentang 1101–9671
V-04	Seluruh nilai luas harus dapat dikonversi ke numerik	Blocker	Konversi lalu hitung NaN	Lulus — 0 gagal konversi dari 4.635 sel
V-05	Luas tidak boleh negatif	Blocker	`luas_ha < 0`	Lulus — 0 nilai negatif
V-06	Dua digit awal kode wilayah harus merupakan kode provinsi sah	Peringatan	Join ke referensi BPS	Lulus — 514 dari 514 terpetakan ke 38 provinsi
V-07	Baris agregat harus sama dengan jumlah baris rinci per tahun	Blocker	Selisih per tahun	**Gagal — tahun 2023 selisih 154.657,05 ha**

Log ketidaksesuaian V-07

Tahun	Baris agregat `Total`	Jumlah 514 kabupaten	Selisih (ha)	Selisih (%)	Status
2018	518.183,00	518.183,00	0,00	0,0%	Cocok
2019	1.625.383,00	1.625.383,00	0,00	0,0%	Cocok
2020	283.047,00	283.047,00	0,00	0,0%	Cocok
2021	351.529,00	351.529,00	0,00	0,0%	Cocok
2022	205.228,00	205.228,00	0,00	0,0%	Cocok
2023	1.161.156,91	1.006.499,86	**154.657,05**	**13,3%**	**Tidak cocok**
2024	376.805,06	376.805,06	0,00	0,0%	Cocok
2025	359.619,35	359.619,35	0,00	0,0%	Cocok

Tahun	Baris agregat `Total`	Jumlah 514 kabupaten	Selisih (ha)	Selisih (%)	Status
2026	202.010,96	202.010,96	0,00	0,0%	Cocok

Script validasi

```
# 03_validasi.py — menjalankan aturan dan menulis log ketidaksesuaian
import re
import pandas as pd

TAHUN = [str(t) for t in range(2018, 2027)]

def ke_angka(s: pd.Series) -> pd.Series:
    """'1.091,18' -> 1091.18"""
    return pd.to_numeric(
        s.astype(str).str.replace(".", "", regex=False)
                     .str.replace(",", ".", regex=False),
        errors="coerce",
    )

def validasi(mentah: pd.DataFrame) -> pd.DataFrame:
    df = mentah.copy()
    for t in TAHUN:
        df[t] = ke_angka(df[t])

    agregat = df[df["Kode Wilayah"].isna()]
    rinci = df[df["Kode Wilayah"].notna()]
    hasil = []

    hasil.append(("V-02", "Kode wilayah unik", "blocker",
                  int(rinci["Kode Wilayah"].duplicated().sum()) == 0))
    hasil.append(("V-03", "Kode wilayah 4 digit", "blocker",
                  bool(rinci["Kode Wilayah"].str.fullmatch(r"\d{4}").all())))
    hasil.append(("V-04", "Luas dapat dikonversi numerik", "blocker",
                  int(rinci[TAHUN].isna().sum().sum()) == 0))
    hasil.append(("V-05", "Luas tidak negatif", "blocker",
                  bool((rinci[TAHUN] >= 0).all().all())))

    for t in TAHUN:
        selisih = float(agregat[t].iloc[0]) - float(rinci[t].sum())
        hasil.append((f"V-07/{t}", "Agregat sama dengan jumlah rinci",
                      "blocker", abs(selisih) < 0.01))
    return pd.DataFrame(hasil, columns=["kode", "aturan", "tingkat",
"lulus"])
```

Tindak lanjut temuan

1. Selisih 2023 dilaporkan ke walidata sebagai permintaan klarifikasi tertulis, bukan diperbaiki sendiri. Memaksa angka agar cocok akan menghapus jejak masalah tanpa menyelesaikannya.
2. Hipotesis kerja: terdapat satu atau beberapa wilayah yang tercakup dalam agregat 2023 tetapi barisnya tidak terbawa ke berkas, kemungkinan terkait pemekaran provinsi di Papua. Hipotesis ini belum dapat dibuktikan dari berkas yang ada.
3. Sampai klarifikasi diterima, seluruh analisis memakai penjumlahan baris kabupaten (1.006.499,86 ha untuk 2023), bukan baris agregat, dan angka 2023 di dashboard diberi penanda kualitas data.
4. Aturan V-07 dipasang permanen di pipeline agar selisih serupa terdeteksi pada muat berikutnya, bukan ditemukan belakangan.

Unit 6 — J.62DMI00.007.1 Menentukan objek data

Objek data ditetapkan sebagai satu tabel fakta pada granularitas **satu kabupaten/kota dalam satu tahun**, dengan kunci utama gabungan `(kode_kab, tahun)`. Penetapan granularitas ini yang mengeluarkan baris `Total` dari tabel fakta: baris tersebut berada pada granularitas nasional, bukan kabupaten, dan mencampurnya akan menggandakan seluruh angka.

Entitas yang diidentifikasi

Entitas	Jenis	Granularitas	Kunci	Jumlah baris
`fakta_karhutla`	Fakta	Kabupaten × tahun	`(kode_kab, tahun)`	4.626
`dim_wilayah`	Dimensi	Kabupaten/kota	`kode_kab`	514
`dim_tahun`	Dimensi	Tahun	`tahun`	9
`audit_agregat`	Audit	Tahun	`tahun`	9

Kamus data — `fakta_karhutla`

Kolom	Tipe	Wajib	Satuan	Definisi	Aturan nilai
`kode_kab`	string(4)	Ya	—	Kode wilayah BPS kabupaten/kota	4 digit, ada di `dim_wilayah`
`tahun`	integer	Ya	tahun	Tahun kejadian kebakaran	2018–2026

Kolom	Tipe	Wajib	Satuan	Definisi	Aturan nilai
`luas_ha`	decimal(12,2)	Ya	hektare	Luas lahan dan hutan terbakar sepanjang tahun	≥ 0
`sumber_berkas`	string	Ya	—	Nama berkas asal baris	Diisi otomatis
`tanggal_muat`	date	Ya	—	Tanggal baris dimuat ke tabel fakta	Diisi otomatis

Kamus data — `dim_wilayah`

Kolom	Tipe	Wajib	Definisi	Aturan nilai
`kode_kab`	string(4)	Ya	Kode wilayah BPS, kunci utama	Unik, 4 digit
`nama_kab`	string	Ya	Nama kabupaten/kota yang telah dibakukan	Title Case, tanpa spasi ganda
`kode_prov`	string(2)	Ya	Dua digit pertama `kode_kab`	11–96
`nama_prov`	string	Ya	Nama provinsi hasil pemetaan	Salah satu dari 38 provinsi
`tipe_wilayah`	string	Ya	Kota atau Kabupaten	Diturunkan dari awalan nama

Kamus data — `dim_tahun`

Kolom	Tipe	Wajib	Definisi	Aturan nilai
`tahun`	integer	Ya	Tahun pelaporan, kunci utama	2018–2026
`status_kelengkapan`	string	Ya	Penanda tahun penuh atau berjalan	`lengkap` atau `parsial`
`catatan_kualitas`	string	Tidak	Catatan temuan validasi pada tahun tersebut	Teks bebas

Keputusan penetapan objek data

1. **Kunci memakai kode, bukan nama.** Nama daerah berubah ejaan antarsumber dan satu di antaranya terbukti bermasalah (`KOTA BANDA ACEH` dengan spasi ganda). Kode wilayah stabil dan unik.

2. **Bentuk long, bukan wide.** Tabel wide memaksa penambahan kolom setiap tahun baru dan menyulitkan agregasi lintas tahun. Bentuk long membuat penambahan tahun hanya menambah baris.
3. **Provinsi sebagai turunan, bukan kolom bebas.** Diturunkan dari dua digit pertama kode wilayah sehingga tidak mungkin tidak konsisten dengan kabupatennya.
4. **Baris agregat disimpan, tidak dibuang.** Dipindahkan ke `audit_agregat` agar aturan rekonsiliasi V-07 tetap dapat dijalankan pada setiap muat.

Unit 7 — J.62DMI00.008.1 Membersihkan Data

Pembersihan mengubah 515 baris × 11 kolom teks menjadi 4.626 baris fakta numerik, melalui enam keputusan yang seluruhnya dicatat alasannya. Tidak ada satu pun nilai luas yang dibuang atau diubah besarannya.

Keputusan pembersihan

#	Masalah ditemukan	Keputusan	Alasan	Baris terdampak
1	Baris `Total` bercampur di level kabupaten	Dipindahkan ke tabel `audit_agregat`	Granularitas berbeda; jika ikut diagregasi, seluruh total menjadi dua kali lipat	1
2	Angka berformat Indonesia tersimpan sebagai teks	Hapus titik ribuan, koma diganti titik, cast ke float	Tidak dapat diagregasi dalam bentuk teks	4.626 sel
3	Header kolom tahun bertipe campuran (teks dan integer)	Seluruh nama kolom dinormalisasi ke string	Perulangan atas kolom tahun gagal jika tipe campuran	9 kolom
4	`KOTA BANDA ACEH` mengandung spasi ganda	Trim dan rapatkan spasi berurutan	Nama ganda mencegah join dan memunculkan dua entri di filter dashboard	1
5	Seluruh nama daerah huruf kapital	Dibakukan ke Title Case, singkatan dipertahankan	Keterbacaan pada label dashboard	514

#	Masalah ditemukan	Keputusan	Alasan	Baris terdampak
6	Struktur wide, satu kolom per tahun	Unpivot menjadi `tahun` dan `luas_ha`	Analisis lintas tahun dan penambahan tahun baru tanpa ubah skema	514 → 4.626

Yang sengaja tidak diubah

Kondisi	Keputusan	Alasan
1.266 nilai `0` tersebar di seluruh tahun	Dipertahankan sebagai nol sahih	73 kabupaten bernilai 0 sepanjang 9 tahun hampir seluruhnya kota tanpa lahan terbuka; mengubahnya menjadi kosong akan menghilangkan informasi
758 nilai di atas batas IQR (>738,98 ha)	Dipertahankan seluruhnya	Pada data kebakaran, nilai ekstrem adalah peristiwa nyata dan justru menjadi objek analisis, bukan galat
Selisih agregat 2023 sebesar 154.657,05 ha	Tidak dipaksa cocok	Diteruskan sebagai permintaan klarifikasi ke walidata; lihat Unit 5
Nilai 2026 yang belum lengkap	Dipertahankan apa adanya, diberi penanda `parsial`	Menghapusnya menghilangkan data tahun berjalan yang dibutuhkan monitoring

Script pembersihan

```
# 04_bersihkan.py — membentuk tabel fakta dan dimensi
import re
import pandas as pd

TAHUN = [str(t) for t in range(2018, 2027)]
PROV = {
    "11": "Aceh", "12": "Sumatera Utara", "13": "Sumatera Barat",
    "14": "Riau", "15": "Jambi", "16": "Sumatera Selatan",
    # ... 38 provinsi, dimuat dari referensi/kode_provinsi.csv
}
```

```
def ke_angka(s: pd.Series) -> pd.Series:
    return pd.to_numeric(
        s.astype(str).str.replace(".", "", regex=False)
                     .str.replace(",", ".", regex=False),
        errors="coerce",
    )

def rapikan_nama(s: pd.Series) -> pd.Series:
    return (s.str.strip()
             .str.replace(r"\s+", " ", regex=True)
             .str.title())

def bersihkan(mentah: pd.DataFrame):
    df = mentah.copy()
    df.columns = [str(c).strip() for c in df.columns]

    # 1. pisahkan baris agregat dari baris rinci
    agregat = df[df["Kode Wilayah"].isna()].copy()
    rinci = df[df["Kode Wilayah"].notna()].copy()

    # 2. konversi angka, 3. bakukan nama, 4. kunci 4 digit
    for t in TAHUN:
        rinci[t] = ke_angka(rinci[t])
        agregat[t] = ke_angka(agregat[t])
    rinci["nama_kab"] = rapikan_nama(rinci["Kabupaten"])
    rinci["kode_kab"] = rinci["Kode Wilayah"].str.zfill(4)

    # 5. dimensi wilayah
    dim_wilayah = rinci[["kode_kab", "nama_kab"]].copy()
    dim_wilayah["kode_prov"] = dim_wilayah["kode_kab"].str[:2]
    dim_wilayah["nama_prov"] = dim_wilayah["kode_prov"].map(PROV)
    dim_wilayah["tipe_wilayah"] = dim_wilayah["nama_kab"].apply(
        lambda n: "Kota" if n.startswith("Kota ") else "Kabupaten"
    )

    # 6. unpivot wide -> long
    fakta = (rinci.melt(id_vars=["kode_kab"], value_vars=TAHUN,
                        var_name="tahun", value_name="luas_ha")
                  .astype({"tahun": int})
                  .sort_values(["kode_kab", "tahun"])
                  .reset_index(drop=True))
    fakta["sumber_berkas"] = "luas-karhutla-kota.xlsx"
    fakta["tanggal_muat"] = pd.Timestamp.today().normalize()

    dim_tahun = pd.DataFrame({"tahun": [int(t) for t in TAHUN]})
```

```
    dim_tahun["status_kelengkapan"] = dim_tahun["tahun"].apply(
        lambda t: "parsial" if t == 2026 else "lengkap"
    )
    return fakta, dim_wilayah, dim_tahun, agregat
```

Hasil sebelum dan sesudah

Ukuran	Sebelum	Sesudah
Bentuk tabel	Wide, 515 × 11	Long, 4.626 × 5
Baris kabupaten/kota	515 (termasuk agregat)	514
Tipe kolom luas	`object` (teks)	`float64`
Sel gagal dikonversi	—	0
Nilai kosong	1 (`Kode Wilayah`)	0
Nama daerah tidak baku	1	0
Kolom provinsi	Tidak ada	Ada, 38 provinsi terpetakan
Penanda kelengkapan tahun	Tidak ada	Ada, 8 `lengkap` + 1 `parsial`
Total nasional 2025 (uji silang)	359.619,35	359.619,35

Baris terakhir adalah uji penutup: total 2025 sebelum dan sesudah pembersihan identik, membuktikan tidak ada nilai yang hilang atau berubah selama proses.

Unit 8 — J.62DMS00.015.1 Membuat Business Intelligence

Dashboard dibangun di Power BI di atas model bintang hasil Unit 6, dengan satu halaman utama yang menjawab pertanyaan prioritisasi anggaran dan satu halaman kualitas data yang membuat temuan validasi terlihat, bukan tersembunyi.

Model data dashboard

Tabel	Peran	Relasi
`fakta_karhutla`	Fakta	Many-to-one ke `dim_wilayah` lewat `kode_kab`; many-to-one ke `dim_tahun` lewat `tahun`
`dim_wilayah`	Dimensi	Hierarki `nama_prov` → `nama_kab`

Tabel	Peran	Relasi
`dim_tahun`	Dimensi	Menyediakan filter tahun dan penanda `status_kelengkapan`
`audit_agregat`	Tabel audit	Tanpa relasi; dipakai khusus pada halaman kualitas data

Definisi KPI

KPI	Definisi	Formula DAX	Alasan dipilih
Total luas terbakar	Jumlah luas pada konteks filter aktif	`Total Luas = SUM(fakta_karhutla[luas_ha])`	Angka utama yang ditanyakan semua pemangku kepentingan
Jumlah daerah terdampak	Banyaknya kabupaten dengan luas > 0	`Daerah Terdampak = CALCULATE(DISTINCTCOUNT(fakta_karhutla[kode_kab]), fakta_karhutla[luas_ha] > 0)`	Mengukur sebaran, yang bergerak berlawanan arah dengan total
Median luas daerah terdampak	Nilai tengah luas pada daerah terdampak	`Median Terdampak = MEDIANX(FILTER(fakta_karhutla, fakta_karhutla[luas_ha] > 0), fakta_karhutla[luas_ha])`	Sebaran sangat miring; rata-rata menyesatkan
Perubahan terhadap tahun lalu	Selisih persen total terhadap tahun sebelumnya	`YoY % = DIVIDE([Total Luas] - CALCULATE([Total Luas], DATEADD(dim_tahun[tahun], -1, YEAR)), CALCULATE([Total Luas], DATEADD(dim_tahun[tahun], -1, YEAR)))`	Dipakai unit monitoring dan evaluasi
Konsentrasi 10 daerah teratas	Porsi 10 kabupaten terbesar terhadap total	`Konsentrasi Top10 = DIVIDE(CALCULATE([Total Luas], TOPN(10, ALLSELECTED(dim_wilayah[nama_kab]), [Total Luas])), CALCULATE([Total Luas], ALLSELECTED(dim_wilayah)))`	Dasar argumen prioritisasi anggaran
Daerah terbakar berulang	Jumlah kabupaten dengan luas > 0 pada ≥ 7 dari 9 tahun	`Berulang = COUNTROWS(FILTER(VALUES(dim_wilayah[kode_kab]), CALCULATE(COUNTROWS(FILTER(fakta_karhutla, fakta_karhutla[luas_ha] > 0))) >= 7)`	Menandai kebutuhan intervensi permanen, bukan tanggap darurat

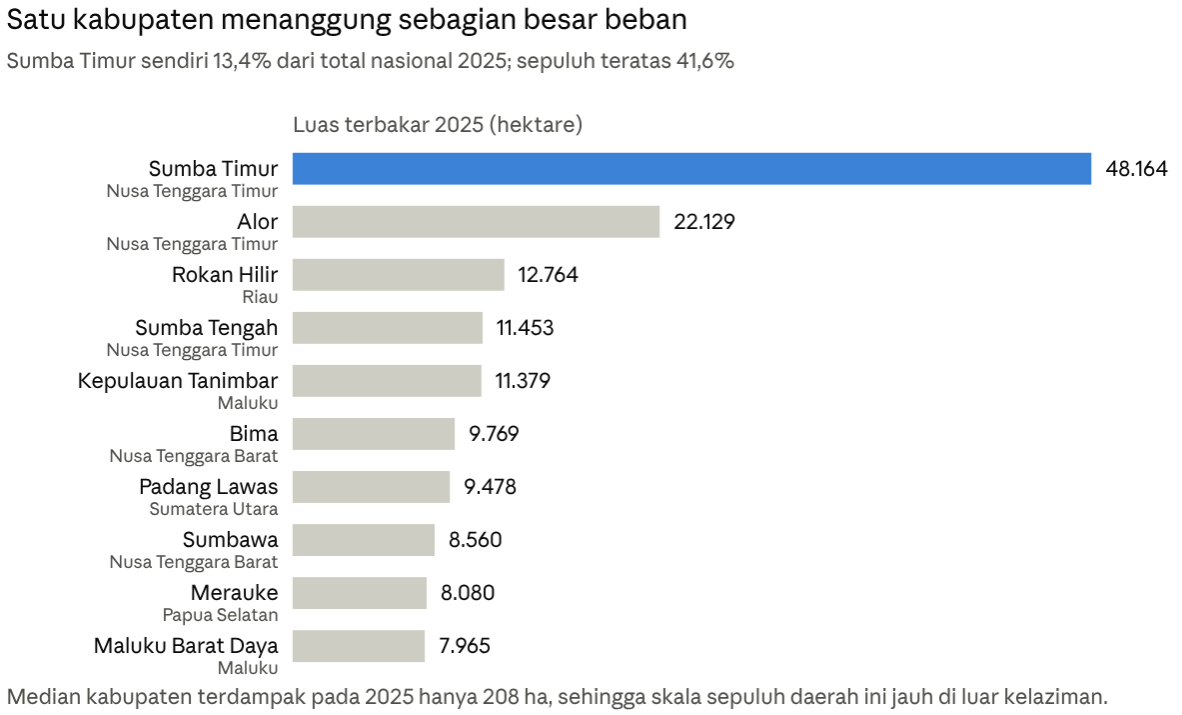
Rancangan halaman dashboard



wireframe dashboard Power BI · 2 halaman, 4 kartu KPI, 4 panel visual

Halaman kedua bukan pelengkap. Menempatkan hasil validasi di dalam dashboard, bukan di lampiran laporan, membuat pengguna tahu angka mana yang belum tuntas sebelum mereka mengutipnya.

Peringkat daerah prioritas, 2025



luas-karhutla-kota.xlsx · 10 kabupaten teratas tahun 2025 dari 514 kabupaten/kota

Visual inilah yang dipakai pada panel kiri dashboard, dengan pemotong tahun dan provinsi aktif, sehingga pengguna dapat menurunkan peringkat ini ke satu provinsi untuk rapat anggaran daerah.

Aturan penyajian yang dipakai

1. Tahun 2026 selalu diberi label `data berjalan` pada setiap visual yang memuatnya, dan dikeluarkan dari perhitungan rata-rata historis.
2. Angka 2023 membawa ikon peringatan yang mengarah ke halaman kualitas data berisi selisih 154.657,05 ha.
3. Kartu KPI menampilkan median berdampingan dengan total; rata-rata tidak ditampilkan sama sekali.
4. Skala warna peta memakai skala kuantil, bukan linear, karena sebaran yang miring membuat skala linear mewarnai hampir seluruh peta dengan satu warna.

Insight dan rekomendasi

1. **Prioritaskan 20 kabupaten, bukan 514.** Dua puluh daerah teratas menanggung 53,8% luas terbakar 2018–2026. Mengalokasikan separuh anggaran pencegahan ke 20 daerah ini menjangkau separuh masalah dengan biaya koordinasi yang jauh lebih kecil.

2. **Nusa Tenggara Timur adalah prioritas nasional yang paling sering terlewat.** NTT menyumbang 862.908 ha kumulatif, tertinggi dari seluruh provinsi, dan masih memimpin pada 2025 dengan 118.409 ha — tiga kali lipat provinsi peringkat kedua. Perhatian publik selama ini tertuju ke Riau dan Kalimantan, sementara Riau hanya menempati peringkat kedelapan kumulatif.
3. **Ubah indikator kinerja dari total luas menjadi jumlah daerah terdampak.** Total nasional turun 78% dari puncak 2019, tetapi jumlah kabupaten terdampak naik dari 226 menjadi 358. Program yang dinilai hanya dari total luas akan terlihat berhasil sementara penyebarannya memburuk.
4. **Siapkan kapasitas tahun El Niño secara terpisah.** 2019 dan 2023 masing-masing 2,8 dan 1,7 kali rata-rata. Anggaran berbasis rata-rata akan selalu kurang pada tahun puncak dan berlebih pada tahun normal; dana siaga terpisah lebih tepat daripada menaikkan pagu rutin.
5. **Selesaikan selisih 2023 sebelum angka dipublikasikan lagi.** Selisih 13,3% pada satu tahun cukup besar untuk membatalkan kesimpulan perbandingan antartahun jika ditemukan pihak luar lebih dulu.

Lampiran

Struktur berkas proyek

```
portofolio-karhutla/
├─ raw/
│  └─ luas-karhutla-kota.xlsx        # berkas sumber, tidak pernah diubah
├─ referensi/
│  └─ kode_provinsi.csv              # 38 kode dan nama provinsi BPS
├─ src/
│  ├─ 01_kumpulkan.py                # Unit 3 — akuisisi + log + hash
│  ├─ 02_telaah.py                   # Unit 4 — profiling dan statistik
deskriptif
│  ├─ 03_validasi.py                 # Unit 5 — 7 aturan + log
ketidaksesuaian
│  ├─ 04_bersihkan.py                # Unit 7 — fakta + dimensi
│  └─ 05_ekspor_bi.py                # Unit 8 — keluaran untuk Power BI
├─ interim/
│  ├─ mentah.parquet
│  └─ log_akuisisi.json
├─ output/
│  ├─ fakta_karhutla.csv             # 4.626 baris
│  ├─ dim_wilayah.csv                # 514 baris
│  ├─ dim_tahun.csv                  # 9 baris
```

```
|  ├─ audit_agregat.csv              # 9 baris
|  └─ log_validasi.csv
└─ bi/
   └─ dashboard_karhutla.pbix
```

Contoh keluaran `fakta_karhutla.csv`

```
kode_kab,tahun,luas_ha,sumber_berkas,tanggal_muat
1101,2018,429.00,luas-karhutla-kota.xlsx,2026-10-14
1101,2019,20.00,luas-karhutla-kota.xlsx,2026-10-14
1101,2020,41.00,luas-karhutla-kota.xlsx,2026-10-14
1101,2021,407.00,luas-karhutla-kota.xlsx,2026-10-14
1101,2022,862.00,luas-karhutla-kota.xlsx,2026-10-14
1101,2023,31.87,luas-karhutla-kota.xlsx,2026-10-14
1101,2024,1158.08,luas-karhutla-kota.xlsx,2026-10-14
1101,2025,1917.47,luas-karhutla-kota.xlsx,2026-10-14
1101,2026,726.96,luas-karhutla-kota.xlsx,2026-10-14
```

Checklist kesiapan asesmen

- [ ] Isi nama lengkap peserta pada tabel identitas
- [ ] Lampirkan tangkapan layar dashboard Power BI untuk Unit 8
- [ ] Lampirkan keluaran terminal `03_validasi.py` sebagai bukti eksekusi
- [ ] Siapkan berkas `.pbix` atau tautan Looker Studio yang dapat dibuka asesor
- [ ] Cetak kamus data Unit 6 sebagai lampiran terpisah
- [ ] Siapkan jawaban lisan untuk pertanyaan: mengapa baris `Total` tidak dibuang saja
- [ ] Siapkan jawaban lisan untuk pertanyaan: mengapa outlier tidak dihapus
- [ ] Siapkan jawaban lisan untuk pertanyaan: mengapa selisih 2023 tidak dikoreksi sendiri

Sumber data

Berkas `luas-karhutla-kota.xlsx` yang diunggah peserta, berisi luas kebakaran hutan dan lahan per kabupaten/kota tahun 2018–2026 dalam satuan hektare. Seluruh angka dalam portofolio ini dihitung ulang dari berkas tersebut; tidak ada angka yang diambil dari sumber luar.